




HIERARCHICZNY K-MEANS JAKO METODA RANKINGU DANYCH

**NA PODSTAWIE ARTYKUŁU:
AUTOMATIC DATA CURATION FOR SELF-SUPERVISED
LEARNING: A CLUSTERING-BASED APPROACH**

**MATEUSZ STASIAK
DAMINIKA DZERANHOUSKAYA**



JAK DZIAŁA METODA HKM





ZAŁOŻENIA NASZYCH BADAŃ

PYTANIE



Czy hierarchiczny k-means pozwala wybrać lepiej zbalansowany podzbiór niż losowanie — i w jakich warunkach ta przewaga się pojawia?

CEL 1



Ocenić jak HKM wybiera obserwacje na podstawie różnych reprezentacji i jak wygląda ta wybierana przestrzeń

CEL 2



Zbadać wpływ metody na jakość trenowanych modelu


CEL 3



Zbadać jak balans klas początkowego zbioru wpływa na skuteczność metody.



GEOMETRIA SELEKCJI







ZBIÓR DANYCH

Imagenette-160 — podzbiór 10 klas ImageNet zawierający łącznie ~9 500 obrazów treningowych i ~3 900 walidacyjnych. Zbiór jest z natury zbalansowany: każda klasa liczy ~950 obrazów, co czyni go idealnym punktem wyjścia do kontrolowanego badania wpływu kuracji.



Rozkład klas Imagenette (train) — ~jednostajny
entropia_norm=1.000 (1.0=idealny), max:min=1.16





JAK MODELE REPREZENTUJĄ PRZESTRZEŃ DANYCH

Przestrzenie embeddingów: DINOv2 vs ResNet-ImageNet vs ResNet-Places365

DINOv2


ResNet-ImageNet

ResNet-Places365




JAK RANDOM WYBIERA PODZBIÓR 20%

Podzbiór 20% — metoda: Random (niezależny na każdej przestrzeni)
(każda kolumna = osobny HKM/Random na własnych embeddingach)



JAK HKM WYBIERA PODZBIÓR 20%

Podzbiór 20% — metoda: HKM (niezależny na każdej przestrzeni)
(każda kolumna = osobny HKM/Random na własnych embeddingach)







WPŁYW KURACJI NA JAKOŚĆ MODELU



CZY FINE-TUNING NA MAŁYM PODZBIORZE MA SENS?

Wpływ reżimu treningu na jakość modelu
Ewaluator: ResNet-ImageNet | Kuracja: HKM-DINO | Podzbiór: 20% (~2000 próbek)







DLA EWALUATORA PLACES365

Wpływ reżimu treningu na jakość modelu
Ewaluator: ResNet-Places365 | Kuracja: HKM-DINO | Podzbiór: 20% (~2000 próbek)

Frozen (linear probe)




Unfrozen (fine-tuning)





TEN SAM EWALUATOR RÓŻNE REPREZENTACJE






HKM NA ZBIORZE Z DŁUGIM OGONEM




TRZY NIEZBALANSOWANE PODZBIORY Z DŁUGIM OGONEM

Pule long-tail (rozkład potęgowy klas)


$\alpha=0.5$ | $N=4932$
entropy_norm=0.972




$\alpha=1.0$ | $N=2856$
entropy_norm=0.873




$\alpha=2.0$ | $N=1487$
entropy_norm=0.549



KTÓRE EMBEDINGI DAJĄ NAJLEPSZE ZBALANSOWANIE




PLACES365 – MIARY BALANSU NA TRZECH ZBIORACH





PLACES365 – JAKOŚĆ MODELU


Downstream na puli long-tail ($\alpha=1.0$), kurator Places365, ewaluator ResNet-ImageNet frozen




STRASZNY UNDERSAMPLING KLAS DOMINUJĄCYCH

Podzbiór na puli long-tail w przestrzeni Places365 (szary = pula, kolor = wybrane próbki, kolor punktu = klasa)

HKM-Places365 20% (pula LT $\alpha=1.0$)



Random 20% (pula LT $\alpha=1.0$)





DZIĘKUJEMY

za uwagę